

AIPanel – Documentos Estratégicos y Técnicos

Este documento reúne tres partes clave solicitadas: 1. **Aspectos diferenciadores frente a ChatGPT Pro y otras plataformas.** 2. **Documento técnico: TENANT_ISOLATION.md.** 3. **Análisis S3 vs Base de Datos (costos, velocidad y almacenamiento de memoria).**

1. Aspectos Diferenciadores de AIPanel

1.1. Memoria Persistente por Tenant y por Agente

A diferencia de ChatGPT Pro, AIPanel ofrece memoria permanente: - Recuerda información histórica. - Mantiene conocimiento del negocio. - Soporta aprendizaje incremental estructurado. - Permite documentación, catálogos, manuales, datos de clientes, procesos internos, etc.

1.2. Multi-Tenant Real para Empresas y Proveedores

ChatGPT es personal o de equipo. AIPanel permite: - Múltiples empresas aisladas. - Múltiples usuarios dentro de cada tenant. - Roles y permisos. - Separación estricta de datos y recursos. - Ideal para MSPs, agencias, proveedores de servicios y empresas.

1.3. Agentes Autónomos (Workers Asíncronos)

AIPanel permite tareas que se ejecutan solas: - Procesos diarios/semanales. - Lectura automática de documentos. - Generación de reportes. - Monitoreo y alertas. - Webhooks.

ChatGPT no tiene agentes autónomos.

1.4. Integración Nativa con Herramientas Externas

AIPanel puede integrarse con: - WhatsApp / SMS / Email. - CRMs. - ERPs. - Zabbix. - Telefonía IP (Asterisk / VitalPBX). - Sistemas propios del cliente. - Comercio electrónico (Shopify / WooCommerce).

ChatGPT no se conecta nativamente a sistemas reales.

1.5. RAG Avanzado con Documentos Pesados

AIPanel soporta: - PDF pesados. - Chunking inteligente. - Resúmenes automáticos. - Buscador híbrido. - Índices por palabras clave.

1.6. Modelos Configurables

Por tenant y agente: - Temperatura. - System prompt dinámico. - Máximo de tokens. - Reglas del agente. - Integración con bases de datos.

1.7. Telefonía con IA

AIPanel permite: - Bots telefónicos. - IVR inteligente. - Llamadas automáticas. - Atención autónoma 24/7.

ChatGPT solo tiene voz local sin integraciones reales.

1.8. Soberanía y Control de Datos

- Hosting en Chile.
- Segmentación por tenant.
- Retención configurada.
- Cumplimiento regulatorio.

1.9. Facturación Local (Chile)

- Transbank.
- Pesos chilenos.
- Suscripciones locales.
- Factura electrónica.
- Pagos recurrentes.

1.10. Auditoría y Monitoreo Empresarial

- Logs por tenant.
- Auditoría completa.
- Métricas detalladas.
- Alertas automáticas.

2. TENANT_ISOLATION.md – Diseño Técnico

2.1. Objetivo

Garantizar aislamiento completo entre tenants en un sistema multi-tenant, a nivel de: - Base de datos. - API. - Documentos. - Memoria de agentes. - Procesos asíncronos. - Auditoría y logs.

2.2. Aislamiento en Base de Datos

Tres niveles de protección:

Nivel 1: Filtrado SQL automático (ORM)

- Cada query incluye automáticamente `WHERE tenant_id = X`.
- Implementado mediante dependencias de FastAPI.
- El backend nunca ejecuta queries sin el tenant presente.

Nivel 2: Row-Level Security (opcional)

PostgreSQL soporta RLS:

```
ALTER TABLE agents ENABLE ROW LEVEL SECURITY;  
CREATE POLICY tenant_isolation_policy ON agents  
USING (tenant_id::text = current_setting('app.current_tenant')) ;
```

Nivel 3: Restricción de índices y acceso

- Índices filtrados por tenant.
- Chunks, documentos y agentes siempre incluyen tenant_id.

2.3. Aislamiento en la API

Toda request valida: - Token JWT. - Rol del usuario. - tenant_id del usuario.

Esto bloquea: - Acceso cruzado. - Enumeración de IDs. - Consultas laterales.

2.4. Aislamiento en Procesos Asíncronos

Celery recibe `tenant_id` como parámetro obligatorio.

Ejemplo:

```
process_document.delay(document_id, tenant_id)
```

2.5. Aislamiento de Documentos

Todos los documentos están asociados a: - `tenant_id` - `agent_id`

Si se usa S3:

```
s3://aipanel/{tenant_id}/{document_id}/file.pdf
```

2.6. Aislamiento de Memoria y Contexto

La memoria del agente se almacena por tenant: - Resúmenes. - Embeddings. - Conversaciones. - Datos persistentes.

2.7. Auditoría

Cada acción incluye: - tenant_id - user_id - acción - timestamp - resultado

2.8. Aislamiento en Caché (Redis)

Clave decorada:

```
cache:{tenant_id}:{resource_type}:{resource_id}
```

2.9. Bloqueo de Abuso entre Tenants

- Rate-limit por tenant.
 - Rate-limit por token.
 - Umbrales de uso.
 - Suspensión automática.
-

3. S3 vs Base de Datos – ¿Dónde almacenar documentos y memoria?

3.1. ¿Qué almacenamos?

- Archivos PDF / DOCX / imágenes.
- Texto extraído.
- Chunks.
- Embeddings.
- Resúmenes.
- Metadatos.

3.2. S3 (u otro Object Storage)

Ventajas: - Barato por GB. - Escala horizontal. - Diseño para archivos grandes. - No carga la BD. - Descarga parcial posible.

Desventajas: - Latencia ligeramente mayor. - Requiere manejo de API (S3 client).

3.3. Base de Datos

Ventajas: - Acceso inmediato al texto. - Consistencia fuerte.

Desventajas: - Mucho más caro por GB. - Crece demasiado rápido. - Ralentiza backups y restores.

3.4. Reglas prácticas

✓ **Archivos binarios (PDF, imágenes)**

S3 siempre. - Costos bajos. - No sobrecarga la BD. - Ideal para cientos de MB.

✓ Texto extraído

BD. - Muy rápido para queries. - Ideal para RAG. - Normalmente pesa 3–10x menos que el PDF.

✓ Embeddings

BD o Redis (según volumen).

✓ Memoria persistente del agente

Si es pequeña → BD.

Si es grande → particiones en S3.

3.5. ¿Qué gasta menos GB?

- PDF grande → S3.
- Texto → BD.
- Resúmenes → BD.
- Conversaciones antiguas → S3 (archivado).

3.6. ¿Qué es más rápido?

- Consultas textuales → BD.
- Descarga de archivos → S3.

4. Recomendación Final

1. PDFs a S3.
2. Texto almacenado en BD.
3. Memoria persistente por GB.
4. Conversaciones antiguas a S3 para reducir costo.
5. RAG solo con texto en BD.

Esta combinación optimiza: - Velocidad. - Costos. - Escalabilidad. - Simplicidad del sistema.

¿Quieres ahora que cree **los archivos separados** (uno por cada tema) listos para subir al repo? Solo pídelo y los generamos como archivos individuales.