

S3_vs_BD.md – Estrategia de Almacenamiento para Documentos y Memoria en AIPanel

1. Objetivo

Definir **dónde** y **cómo** almacenar: - Archivos binarios (PDF, DOCX, imágenes). - Texto extraído de documentos. - Chunks y resúmenes. - Conversaciones históricas. - Memoria persistente por tenant y por agente.

Optimizando: - Costos por GB. - Velocidad de acceso. - Escalabilidad. - Simplicidad operativa.

2. Qué tipos de datos manejamos

1. Archivos binarios

2. PDFs originales.
3. DOCX, TXT, imágenes.

4. Texto estructurado

5. Texto extraído de PDFs.
6. Chunks.
7. Resúmenes.
8. Keywords/topics.

9. Conversaciones y memoria

10. Chats con agentes.
 11. Memoria de largo plazo.
 12. Estados intermedios.
 13. **Embeddings** (futuro o ya considerado)
 14. Vectores numéricos.
-

3. Comparación S3 vs Base de Datos

3.1. S3 (Object Storage)

Ventajas: - Diseñado para archivos grandes. - Muy barato por GB. - Alta durabilidad. - Escala horizontal.
- Ideal para almacenamiento a largo plazo.

Desventajas: - Mayor latencia que una consulta directa a BD. - No es cómodo para búsquedas textuales. - Se necesita un cliente S3 y manejo de errores.

Casos ideales: - PDFs originales. - Imágenes. - Archivos históricos que no se leen frecuentemente. - Conversaciones antiguas archivadas.

3.2. Base de Datos (PostgreSQL)

Ventajas: - Consultas rápidas y flexibles. - Ideal para búsquedas textuales. - Facilita joins, filtros y ordenamientos. - Integración directa con el ORM.

Desventajas: - Más caro por GB que S3. - Hacerla crecer con archivos pesados afecta rendimiento. - Backups y restores más lentos con muchos GB.

Casos ideales: - Texto extraído. - Chunks y resúmenes. - Índices de búsqueda. - Metadatos de documentos. - Memoria activa de corto/mediano plazo.

4. Estrategia Recomendada

4.1. PDFs y archivos binarios → S3

Regla general: - TODO archivo original (PDF, DOCX, imagen) se almacena en S3.

Ejemplo de ruta:

```
s3://aipanel/{tenant_id}/{document_id}/original.pdf
```

En la base de datos solo se guarda: - `document_id` - `tenant_id` - `file_path` o `s3_key` - tamaño del archivo en bytes

4.2. Texto extraído → Base de Datos

Tras procesar un PDF: - Se extrae el texto. - Se normaliza (limpieza básica). - Se guarda en BD en la tabla `documents` y sus `document_chunks`.

Ventajas: - Búsqueda rápida. - RAG eficiente. - Resúmenes y keywords disponibles.

4.3. Chunks, resúmenes y keywords → Base de Datos

Todos los elementos que se utilizan en: - Búsquedas. - Resúmenes. - RAG. - Navegación de contenido.

Se almacenan en BD porque: - Su tamaño es mucho menor que el PDF. - Son críticos para respuestas rápidas.

4.4. Conversaciones y memoria

Memoria activa (reciente):

- Guardar en BD.
- Acceso inmediato.
- Filtrado por tenant, agente y usuario.

Memoria histórica (antigua, de poco uso):

- Opción 1: seguir en BD con retención limitada por GB/tenant.
- Opción 2: mover a S3 como archivo comprimido (JSONL, por ejemplo) cuando supera cierto tamaño.

4.5. Embeddings

Opciones: - Guardarlos en BD en una tabla tipo `embeddings`. - Guardarlos en un servicio vectorial externo (futuro).

En ambos casos, el **texto original** del que vienen los embeddings está en BD.

5. Memoria medida por GB y no por tiempo

En lugar de decir "memoria por 3 meses", AIPanel mide la memoria por: - **GB por tenant** (cuota asignada según el plan).

Ejemplo: - Plan Básico: 1 GB memoria total. - Plan Pro: 5 GB. - Plan Enterprise: 20 GB+.

Dentro de esa cuota se suma: - Texto de documentos. - Resúmenes. - Conversaciones activas. - Metadatos.

Cuando se alcanza el límite: - Se aplican políticas de limpieza/archivado.

6. Políticas de Retención según GB

6.1. Límites duros por plan

Cada plan define: - `max_storage_gb` (ej: 1, 5, 20...). - `max_documents` (ej: 100, 1.000, 10.000...).

6.2. Política de limpieza

Opciones combinables:

1. **FIFO de conversaciones:**
2. Las conversaciones más antiguas se archivan (S3) cuando se supera el límite.
3. **Reducir detalle histórico:**

4. Mantener resúmenes en BD.
5. Mover detalle completo a S3.
6. **Eliminar contenido inactivo:**
7. Documentos o chats sin acceso X tiempo.

6.3. Visualización al cliente

El tenant ve en el dashboard: - Uso actual de almacenamiento (GB). - Porcentaje del plan consumido. - Top agentes/documentos que consumen más almacenamiento.

7. Impacto en Costos

7.1. S3

- Muy barato por GB/mes.
- Ideal para grandes volúmenes a largo plazo.

7.2. Base de Datos

- Más cara por GB.
- Ideal para datos calientes (hot data):
- Texto de consulta frecuente.
- Memoria activa.

7.3. Modelo híbrido

Combinación recomendada:

1. S3: archivos originales + archivos de archivo (conversaciones antiguas, logs comprimidos).
2. BD: texto, resúmenes, memoria activa, índices.

Así se optimiza: - Costos de infraestructura. - Rendimiento del sistema. - Experiencia de usuario.

8. Resumen Final

1. **PDF y binarios → S3.**
2. **Texto, chunks y resúmenes → BD.**
3. **Memoria medida en GB por tenant, no por tiempo.**
4. **Memoria activa en BD, histórica en S3 (archivada).**
5. **Planes comerciales definidos por almacenamiento máximo (GB) y cantidad de documentos.**

Esta estrategia mantiene AIPanel: - Rápido para el usuario. - Barato de mantener. - Escalable a muchos tenants y grandes volúmenes de documentos.